Naufal Abdullah R.Z

Proyek Sain Data

To blah, blah, and blah.

Table of contents

Streamlit

link streamlit Dry Bean Streamlit

1

Dry Bean

Nama : Naufal Abdullah Rasyiq Zaki

NIM : 200411100096

1.1 Business Understanding

Tujuan utama dari proyek ini adalah mengembangkan model klasifikasi untuk mengidentifikasi kategori biji-bijian kering berdasarkan fitur yang ada. Hasilnya akan digunakan seperti:

- Membantu untuk mengklasifikasikan biji-bijian kering dari tujuh jenis kacang yang terdaftar berdasarkan fitur-fitur tertentu.
- menyediakan alat identifikasi biji-bijian kering sesuai klasifikasi nya

1.2 Data Understanding

Dataset yang digunakan adalah data Dry Bean yang berasal dari website UCI Machine Learning. Data ini merupakan sebuah dataset kumpulan gambar biji-bijian dari tujuh jenis kacang yang berbeda menggunakan kamera resolusi tinggi. Dataset yang digunakan memiliki 13611 data.

1.2.1 Penjelasan atribut

Berikut ini adalah penjelasan atribut atribut yang digunakan:

1. Area (A) : Luas zona kacang dan jumlah piksel dalam batasnya.
2. Perimeter (P) : Keliling kacang didefinisikan sebagai panjang tepinya.
3. Major axis length (L) : Jarak antara ujung-ujung garis terpanjang yang dapat ditarik dari sebuah kacang.

4. Minor axis length (l) : Garis terpanjang yang dapat ditarik dari kacang sambil berdiri tegak lurus terhadap sumbu utama.
5. Aspect ratio (K) : Mendefinisikan hubungan antara L dan l.
6. Eccentricity (Ec) : Eksentrisitas elips yang momennya sama dengan daerah.
7. Convex area (C) : Jumlah piksel dalam poligon cembung terkecil yang dapat memuat luas biji kacang.
8. Equivalent diameter (Ed) : Diameter lingkaran yang luasnya sama dengan luas biji kacang.
9. Extent (Ex) : Rasio piksel dalam kotak pembatas dengan area kacang.
10. Solidity (S) : Juga dikenal sebagai konveksitas. Rasio piksel pada cangkang cembung dengan piksel pada kacang.
11. Roundness (R): Dihitung dengan rumus berikut: (4piA)/(P^2)
12. Compactness (CO) : Mengukur kebulatan suatu benda: Ed/L
13. ShapeFactor1 (SF1) : Faktor Bentuk 1
14. ShapeFactor2 (SF2) : Faktor Bentuk 2
15. ShapeFactor3 (SF3) : Faktor Bentuk 3
16. ShapeFactor4 (SF4) : Faktor Bentuk 4
17. class (Seker, Barbunya, Bombay, Cali, Dermosan, Horoz and Sira)

1.2.2 Library

```
import matplotlib.pyplot as plt
import pandas as pd
import seaborn as sns
import numpy as np
from sklearn.feature_selection import SelectKBest, f_classif
from sklearn.preprocessing import MinMaxScaler
```

1.2.3 Install dataset dry bean

```
from google.colab import drive
drive.mount('/content/drive')
```

```
Mounted at /content/drive
```

```
import pandas as pd

# Memuat file CSV
df = pd.read_excel('/content/drive/MyDrive/Proyek_Sain_Data/dry+bean+dataset/DryBeanDataset/Dry
```

```
# Menampilkan tabel
df
```

	Area	Perimeter	MajorAxisLength	MinorAxisLength	AspectRation	Eccentricity	ConvexArea	Ec
0	28395	610.291	208.178117	173.888747	1.197191	0.549812	28715	
1	28734	638.018	200.524796	182.734419	1.097356	0.411785	29172	
2	29380	624.110	212.826130	175.931143	1.209713	0.562727	29690	
3	30008	645.884	210.557999	182.516516	1.153638	0.498616	30724	
4	30140	620.134	201.847882	190.279279	1.060798	0.333680	30417	
...	...	...	...	...	...	...	...	
13606	42097	759.696	288.721612	185.944705	1.552728	0.765002	42508	
13607	42101	757.499	281.576392	190.713136	1.476439	0.735702	42494	
13608	42139	759.321	281.539928	191.187979	1.472582	0.734065	42569	
13609	42147	763.779	283.382636	190.275731	1.489326	0.741055	42667	
13610	42159	772.237	295.142741	182.204716	1.619841	0.786693	42600	

```
X = df.drop(['Class'], axis=1)
y = df["Class"]
```

1.2.4 Missing value

Cek apakah ada missing value pada dataset

```
print(X.isnull().sum())  # Menampilkan jumlah missing value untuk setiap kolom
```

```
Area               0
Perimeter          0
MajorAxisLength    0
MinorAxisLength    0
AspectRation       0
Eccentricity       0
ConvexArea         0
EquivDiameter      0
Extent             0
Solidity           0
roundness          0
Compactness        0
ShapeFactor1       0
ShapeFactor2       0
ShapeFactor3       0
ShapeFactor4       0
```

```
dtype: int64
```

1.2.5 Visualisasi

```
# Menghitung jumlah hewan dengan nilai legs tertentu
legs_counts = y.value_counts().sort_index()

# Membuat diagram garis untuk distribusi jumlah hewan berdasarkan jumlah kaki (legs)
plt.figure(figsize=(8, 6))
plt.plot(legs_counts.index, legs_counts.values, marker='o', color='skyblue', linestyle='-', lin
plt.xlabel('Jumlah Kategori biji')
plt.ylabel('Jumlah biji kering')
plt.title('Distribusi Jumlah biji pada setiap kategori biji')
plt.xticks(legs_counts.index)
plt.grid(axis='y', linestyle='--', alpha=0.7)

# Menambahkan label jumlah hewan pada setiap titik pada diagram
for i, count in enumerate(legs_counts.values):
    plt.text(legs_counts.index[i], count, str(count), ha='center', va='bottom')

plt.tight_layout()
plt.show()
```

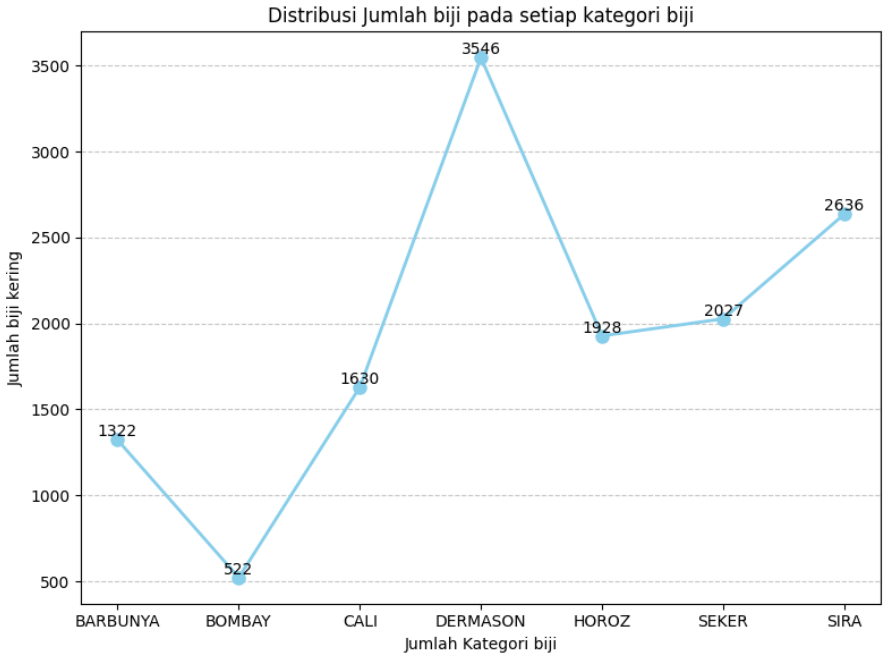

Pada distribusi class ini, terlihat bahwa data dominan biji dermanson berjumlah 3546 biji, sira berjumlah 2636, seker berjumlah 2027, horoz berjumlah 1928, barbuya berjumlah 1322 dan data yang paling sedikit yaitu biji bombay yang hanya berjumlah 522

1.2.6 Seleksi Fitur

sebelum melakukan preprocessing data alangkah baiknya untuk menyeleksikan fitur fitur yang menurut kita adalah fitur yang tidak berpengaruh terhadap dataset dan mengurangi beban dataset agar tidak menyebabkan overfitting

Disini saya menggunakan sckit learn untuk melakukan selection pada fitur - yang pertama saya menentukan banyaknya fitur terdapat N = banyak fitur, fitur yang ada didataset adalah 16 fitur - Jumlah fitur terbaik yang terpilih disesuaikan dengan nilai K di atas - ambil data data pada setiap fitur menggunakan funtion colomns dan nama pada fitur akan dimasukan kedalam selected_feature_names - lalu proses melakukan perhitungan statistik ANOVA dengan rumus

$$F = \frac{MSB}{MSW}$$

MSB atau mean square antar kelompok (mean square between groups). dapat dari rumus ini :

$$MSB = \frac{\sum_{i=1}^{k} n_i(\bar{X}_i - \bar{X}_{\text{total}})^2}{k-1}$$

dan MSW atau mean square dalam kelompok (mean square within groups)

$$MSW = \frac{\sum_{i=1}^{k} \sum_{j=1}^{n_i} (X_{ij} - \bar{X}_i)^2}{N-k}$$

Untuk hasil akhirnya saya menghapus 9 fitur yang menurut saya tidak akan berpengaruh terhadap dataset

```
selector = SelectKBest(score_func=f_classif, k=15)  # K adalah jumlah fitur terbaik yang akan d

# # Lakukan seleksi fitur
selector.fit(X, y)

# # Tampilkan hasil seleksi fitur
# # Jumlah fitur terbaik yang terpilih disesuaikan dengan nilai K di atas
selected_features = selector.get_support(indices=True)
feature_names = X.columns
```

```
# #Pilih nama-nama fitur yang dipilih
selected_feature_names = [feature_names[i] for i in selected_features]

# # Sisa kode Anda tetap sama
# # Hitung skor statistik untuk setiap fitur
scores = selector.scores_[selected_features]


# # Membuat bar chart
plt.figure(figsize=(10, 6))
plt.bar(selected_feature_names, scores, color='skyblue')
plt.xlabel('Fitur')
plt.ylabel('Skor Statistik')
plt.title('Skor Statistik untuk Fitur-Fitur Terpilih')
plt.xticks(rotation=45)
plt.tight_layout()

# # Menampilkan grafik
plt.show()
```

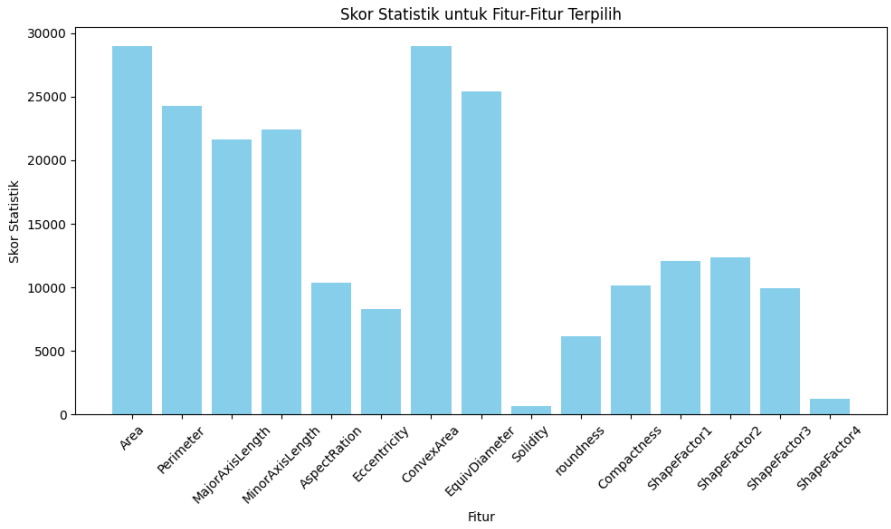


```
X = df.drop(['MinorAxisLength','AspectRation','Solidity','roundness','ShapeFactor4', 'Class'], 
X
```

	Area	Perimeter	MajorAxisLength	Eccentricity	ConvexArea	EquivDiameter	Extent	Compactne
0	28395	610.291	208.178117	0.549812	28715	190.141097	0.763923	0.9
1	28734	638.018	200.524796	0.411785	29172	191.272750	0.783968	0.9
2	29380	624.110	212.826130	0.562727	29690	193.410904	0.778113	0.9
3	30008	645.884	210.557999	0.498616	30724	195.467062	0.782681	0.9
4	30140	620.134	201.847882	0.333680	30417	195.896503	0.773098	0.9
...	...	...	...	...	...	...	...	...
13606	42097	759.696	288.721612	0.765002	42508	231.515799	0.714574	0.8
13607	42101	757.499	281.576392	0.735702	42494	231.526798	0.799943	0.8
13608	42139	759.321	281.539928	0.734065	42569	231.631261	0.729932	0.8
13609	42147	763.779	283.382636	0.741055	42667	231.653248	0.705389	0.8
13610	42159	772.237	295.142741	0.786693	42600	231.686223	0.788962	0.7

untuk membuang fitur yang skor statistik nya rendah

1.3 Preprocesing Data

1.3.1 Split data

train_test_split adalah suatu fungsi dalam library scikit-learn yang digunakan untuk membagi dataset menjadi dua set, yaitu set pelatihan (training set) dan set pengujian (testing set). Pemisahan ini bertujuan untuk melakukan pelatihan model pada set pelatihan dan menguji kinerja model pada set pengujian. Fungsi ini sangat umum digunakan dalam proses machine learning untuk menghindari overfitting dan mengevaluasi kemampuan generalisasi dari model yang telah dilatih

1. test_size (opsional): Menentukan ukuran set pengujian sebagai proporsi dari seluruh dataset. Nilai ini bisa berupa pecahan (misalnya, 0.2 untuk 20%) atau bilangan bulat yang menyatakan jumlah sampel yang akan ditempatkan di set pengujian.
2. random_state (opsional): Digunakan untuk mengontrol randomization selama pembagian dataset. Jika nilai ini diberikan, pemisahan dataset akan tetap konsisten setiap kali fungsi ini dijalankan

```
from sklearn.model_selection import train_test_split
```

```
# Pembagian data menjadi data latih dan data uji (80% data latih, 20% data uji)
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random_state=42)
```

1.3.2 Normalisasi Data

Setelah melakukan understanding data maka melakukan preprocessing yang dimana data akan di jadikan antara 0 sampai 1

dengan menggunakan minmaxScaller untuk menormalisasi data , dan menggunakan train_test_split untuk mendapatkan data training dan data testing

rumus MinmaxScaler:

$$\text{Scaled Value} = \frac{\text{Original Value} - \text{Min}}{\text{Max} - \text{Min}}$$

- Original Value adalah nilai asli dari fitur.

- Min adalah nilai minimum dari fitur.
- Max adalah nilai maksimum dari fitur.

1. fit_transform Fungsinya ini menghitung parameter normalisasi dari dataset (seperti nilai minimum dan maksimum) dan kemudian mengaplikasikan normalisasi pada dataset tersebut. Fungsi ini berguna untuk menghitung parameter normalisasi berdasarkan data pelatihan dan sekaligus menerapkan normalisasi tersebut.
2. Setelah kita telah menggunakan fit_transform pada data pelatihan, kita dapat menggunakan metode transform pada data pengujian (dan data lainnya yang ingin dinormalisasi) menggunakan parameter normalisasi yang telah dihitung sebelumnya. Metode ini hanya melakukan normalisasi tanpa perlu menghitung parameter normalisasi lagi.

```
scaler = MinMaxScaler()
X_train_scaler = scaler.fit_transform(X_train)
X_test_scaler = scaler.transform(X_test)
x = pd.DataFrame(X_train,columns=X.columns)
x
```

Area	Perimeter	MajorAxisLength	Eccentricity	ConvexArea	EquivDiameter	Extent	Compactnes
11073	29076	636.353	235.061516	0.740272	29490	192.407674	0.693524	0.8
13172	38091	755.186	271.077683	0.748513	38716	220.224811	0.706318	0.8
11587	30969	651.527	230.164083	0.664964	31318	198.572293	0.733689	0.8
12492	34589	685.425	253.001232	0.723664	34965	209.857291	0.784331	0.8

Area	Perimeter	MajorAxisLength	Eccentricity	ConvexArea	EquivDiameter	Extent	Compactnes
430	35954	710.093	251.660769	0.690581	36380	213.958067	0.794564	0.8
...	...	...	...	...	...	...	...	...
5191	83266	1117.778	448.473710	0.847920	84030	325.603384	0.797239	0.7
13418	39857	755.392	283.623668	0.774448	40330	225.272077	0.692154	0.7
5390	90004	1156.599	456.836383	0.833583	90790	338.521273	0.783939	0.7
860	38426	711.412	246.696608	0.593467	38799	221.191100	0.752094	0.8
7270	63628	997.390	400.784151	0.860715	64287	284.629032	0.622583	0.7

1.4 Modelling

1.4.1 Random Forest

Rumus umum Random Forest

$$f(x) = \text{sign}\left(\frac{1}{N}\sum_{i=1}^{N} f_i(x) - \theta\right)$$

Dengan penjelasan:
N adalah jumlah pohon dalam hutan, $f_i(x)$ adalah prediksi dari pohon ke-i, dan θ adalah ambang batas

```
from sklearn.ensemble import RandomForestClassifier
from sklearn.metrics import accuracy_score, classification_report


#Buat model Random Forest
random_forest_model = RandomForestClassifier(n_estimators=100)
#Latih model
random_forest_model.fit(X_train, y_train)
#Prediksi dengan model
random_forest_predictions = random_forest_model.predict(X_test)
#Evaluasi kinerja model
random_forest_accuracy = accuracy_score(y_test, random_forest_predictions)
```

1.4.2 Decision Tree

Rumus umum Decision Tree:

$$f(x) = \text{sign}\left(\text{Node}(x) - \theta\right)$$

Dengan penjelasan:
Node(x) : Fungsi keputusan pohon keputusan untuk input x θ : adalah ambang batas (threshold).